



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

PROGRAMA ACADÉMICO DE CIENCIAS DE LA COMPUTACIÓN

INTRODUCTION TO DEEP LEARNING

PRÁCTICA CALIFICADA 2

INTEGRANTES

- Acuña Villegas, Omar Junior - U201613422
- Chui Sanchez, Rafael Tomas - U201925837
- Meza Polo, Rodrigo Alejandro - U202224016
- Pariona Rojas, Axel Yamir - U202222148

PROFESOR:

JAIRO PINEDO TAQUIA

1. Introducción

Motivación del problema

El análisis y la clasificación precisa de células sanguíneas son procesos fundamentales en el diagnóstico clínico, ya que permiten la detección y el monitoreo de diversas condiciones médicas, tales como infecciones, problemas del sistema inmunológico y enfermedades de la sangre (por ejemplo, la leucemia). Tradicionalmente, esta evaluación se realiza mediante una inspección visual bajo el microscopio por parte de especialistas médicos. Sin embargo, esta tarea manual es sumamente tediosa, consume un tiempo valioso y puede estar sujeta a fatiga o errores humanos.

La aplicación de algoritmos de Deep Learning, en especial el uso de Redes Neuronales Convolucionales (CNN), ofrece una alternativa robusta para automatizar la clasificación de imágenes médicas. En este trabajo, el objetivo principal no es únicamente maximizar la precisión en la clasificación, sino comprender de manera empírica el impacto que tienen distintas decisiones de diseño sobre el aprendizaje del modelo. Para ello, analizamos cómo se comportan arquitecturas clásicas de extracción de características (como variantes de LeNet y VGG) ante el problema, e investigamos específicamente la contribución que tiene la técnica de regularización espacial Batch Normalization en la velocidad de convergencia y el rendimiento general de las redes.

Descripción del Dataset

Para entrenar y validar nuestros modelos, se ha utilizado el Blood Cell Image Dataset de dominio público, obtenido a través de Kaggle. Las características principales de este conjunto de datos son las siguientes:

- Está compuesto por aproximadamente 12,500 imágenes reales microscópicas en formato RGB, con una dimensión original de 320x240 píxeles. (Para nuestros experimentos de entrenamiento, se redimensionaron a 64x64 píxeles).
- El objetivo es un problema de clasificación multiclase, enfocado en distinguir 4 tipos específicos de glóbulos blancos.
- Las cuatro categorías a clasificar son: Eosinófilos (EOSINOPHIL), Linfocitos (LYMPHOCYTE), Monocitos (MONOCYTE) y Neutrófilos (NEUTROPHIL).

Al tratarse de imágenes médicas con alto grado de similitud visual y ruido de fondo natural, el dataset resulta un escenario idóneo para contrastar las diferencias de capacidad representativa entre arquitecturas superficiales (LeNet-5) y arquitecturas más profundas (VGG-11).

2. Metodología

Para abordar el problema de clasificación de células sanguíneas, se diseñó un flujo de trabajo que incluye el tratamiento de imágenes, la adaptación de arquitecturas clásicas y la formulación de experimentos comparativos. A continuación, se detallan los componentes principales.

Estrategia de Preprocesamiento y Aumento de Datos

Dado que las imágenes médicas originales tienen dimensiones de 320x240 píxeles, se aplicó un canal de transformación mediante la librería `torchvision.transforms` para estandarizar las entradas y mejorar la generalización del modelo:

Redimensionamiento: Todas las imágenes se ajustaron a una resolución de 64x64 píxeles para optimizar la carga computacional.

Aumento de Datos (Data Augmentation): Exclusivamente para el conjunto de entrenamiento, se introdujeron transformaciones geométricas como volteos horizontales aleatorios (`RandomHorizontalFlip`) y rotaciones aleatorias de hasta 10 grados (`RandomRotation(10)`).

Normalización: Las imágenes se convirtieron a tensores de PyTorch y se normalizaron por canal (RGB) utilizando la media estadística [0.485, 0.456, 0.406] y la desviación estándar [0.229, 0.224, 0.225].

Partición de los datos: Las imágenes se agruparon en batches utilizando `DataLoader`, destinando un 20% del conjunto de entrenamiento original para validación interna.

Arquitecturas y Descripción de Experimentos

El trabajo se estructuró en dos grandes tareas o experimentos para evaluar distintas hipótesis de diseño:

Experimento 1: Comparación Base de Arquitecturas: Se buscó contrastar el desempeño de arquitecturas superficiales frente a arquitecturas profundas. Para ello, se entrenaron desde cero cuatro variantes:

- **LeNet5:** Adaptada para imágenes RGB de 64x64, manteniendo 2 bloques convolucionales y 3 capas densas (aprox. 337,976 parámetros).
- **LeNet5_BN:** Variante con una capa de Batch Normalization (BN) tras cada operación convolucional.
- **VGG11Small:** Una versión simplificada de la clásica red VGG-11, con el número de filtros reducido a la mitad (aprox. 2,963,396 parámetros).
- **VGG11Small_BN:** La variante de VGG-11 simplificada incorporando Batch Normalization.

Experimento 2: Impacto del Learning Rate y Batch Normalization: Con el fin de observar empíricamente cómo Batch Normalization estabiliza el aprendizaje, se comparó el modelo VGG11Small (sin BN) contra VGG11Small_BN (con BN). Se sometieron a prueba bajo tres tasas de aprendizaje distintas (0.001, 0.003 y 0.01).

Hiperparámetros y Configuración General

Para garantizar la reproducibilidad de los resultados, se fijó una semilla global (seed=42) en las librerías random, numpy y torch. Las configuraciones de entrenamiento fueron las siguientes:

- Función de pérdida: Entropía cruzada multiclase (CrossEntropyLoss).
- Optimizador: Algoritmo Adam para todos los entrenamientos.
- Tasa de aprendizaje (LR): Fijada en 0.001 para el Experimento 1. Para el Experimento 2, se varió en el rango [0.001, 0.003, 0.01].
- Tamaño del lote (Batch Size): 32 imágenes por iteración.
- Épocas: Se ejecutaron 15 épocas para el Experimento 1 y 10 épocas para el Experimento 2.
- Durante el bucle de entrenamiento, se implementó una estrategia de guardado del modelo (Model Checkpoint) que conservaba únicamente los pesos de la red con el mejor accuracy en validación.

3. Resultados

En esta sección se presentan los resultados cuantitativos y visuales obtenidos tras el entrenamiento de los modelos descritos en la metodología. La métrica principal de evaluación utilizada es la exactitud (Accuracy) y la función de pérdida (Cross Entropy Loss) sobre los conjuntos de validación y prueba (Test).

3.1. Experimento 1: Comparación Base de Arquitecturas

En la primera fase, se evaluó el desempeño de arquitecturas superficiales (LeNet-5) frente a profundas (VGG11Small), analizando el impacto directo de la incorporación de Batch Normalization (BN).

Tabla 1. Resultados de la comparación base de arquitecturas entrenadas desde cero

Modelo	Parámetros Entrenables	Tiempo prom/época (s)	Best Val Accuracy	Test Accuracy	Test Loss
--------	------------------------	-----------------------	-------------------	---------------	-----------

LeNet	337,976	13.91	0.8262	0.7479	0.7932
LeNet_BN	338,020	13.52	0.8825	0.5131	3.5496
VGG11Small	2,963,396	14.14	0.3737	0.3438	1.3740
VGG11Small_BN	2,966,148	14.64	0.9754	0.8331	1.3317

Como se aprecia en la Tabla 1, entrenar la arquitectura estándar VGG11Small desde cero sin mecanismos de regularización resultó ineficaz (34.38% de accuracy en test). Sin embargo, la incorporación de Batch Normalization estabilizó el flujo de gradientes, permitiendo al modelo VGG11Small_BN alcanzar el mejor rendimiento de esta fase con un 83.31% de exactitud.

3.2. Experimento 2: Impacto del Learning Rate en VGG11Small

En la segunda fase, se analizó la robustez de VGG11Small (con y sin BN) frente a diferentes tasas de aprendizaje (LR: 0.001, 0.003 y 0.01) durante 10 épocas.

Tabla 2. Impacto de distintas tasas de aprendizaje


Modelo	Batch Normalization	Learning Rate	Tiempo prom/época (s)	Best Val Acc	Test Accuracy	Test Loss
VGG11Small_sin_BN	sin BN	0.001	14.13	0.2557	0.2505	1.3864
VGG11Small_con_BN	con BN	0.001	14.43	0.8327	0.8018	0.5163
VGG11Small_sin_BN	sin BN	0.003	14.03	0.2557	0.2505	1.3868
VGG11Small_con_BN	con BN	0.003	14.29	0.8614	0.6900	1.0727
VGG11Small_sin_BN	sin BN	0.010	13.75	0.2557	0.2505	1.3864

VGG11Small_con_BN	con BN	0.010	14.27	0.7107	0.7193	0.4776
-------------------	--------	-------	-------	--------	--------	--------

Los resultados confirman que BN es esencial para la convergencia en redes profundas, ya que las variantes sin BN colapsaron al 25% de exactitud (equivalente al azar) en todas las tasas. Aunque la variante con BN logró un 80.18% con un LR de 0.001, se observó que la red sigue siendo sensible a cambios en este hiperparámetro, disminuyendo su rendimiento ante tasas más agresivas.

3.3. Experimento 3: Transfer Learning y Comparación Final

Para superar el límite del 83.31% alcanzado en las arquitecturas entrenadas desde cero, se implementaron estrategias de Transfer Learning utilizando ResNet-18 preentrenada en ImageNet.





Como se evidencia en la gráfica comparativa superior, la estrategia de Feature Extraction (pesos congelados) se estanca rápidamente, obteniendo un rendimiento bajo (59.43%). Por el contrario, el Fine-Tuning Total destaca como la variante más estable, superando con creces a las demás aproximaciones.

Tabla 3. Comparación entre el mejor modelo desde cero y el mejor Transfer Learning

Modelo	Estrategia	Learning Rate	Parámetros Entrenables	Tiempo promedio/poca	Test Accuracy	Test Loss
VGG11Small_BN	Entrenado desde cero	-	2,966,148	14.67 s	0.8331	1.3317
ResNet18_Fine_Tuning_Total	Fine Tuning Total	0.00001	11,178,564	36.96 s	0.8577	0.5750


Al consolidar a ResNet18_Fine_Tuning_Total como el modelo ganador definitivo (85.77% de Test Accuracy), se analizó su dinámica de aprendizaje a través de sus curvas individuales:



Las gráficas del modelo definitivo demuestran un entrenamiento sumamente estable gracias a la tasa de aprendizaje baja (0.00001). En la curva de pérdida (*Loss*), se observa una caída continua tanto en entrenamiento como en validación, sin signos de divergencia. Paralelamente, la curva de *Accuracy* muestra cómo ambas métricas convergen hacia valores altos, confirmando que la red adaptó exitosamente sus filtros al dominio médico sin caer en *overfitting*.

3.4. Análisis por Clase del Mejor Modelo

Para evaluar el desempeño específico de `ResNet18_Fine_Tuning_Total` en los cuatro tipos de glóbulos blancos, se generó su matriz de confusión.



El modelo identifica de manera perfecta a la clase de Linfocitos (620 verdaderos positivos, sin confusiones). Esto tiene sentido a nivel clínico, dado que su núcleo grande y redondeado los hace morfológicamente muy distintos al resto. Por otro lado, la mayor concentración de errores recae en la distinción entre Neutrófilos (donde 74 se confundieron con eosinófilos) y Eosinófilos (donde 124 se confundieron con neutrófilos). Este índice de falsos positivos cruzados es

esperado, ya que ambas células pertenecen al mismo linaje granulocítico, y los pequeños detalles de textura que las diferencian tienden a perderse al redimensionar las imágenes.

4. Discusión

4.1. Análisis de los resultados

En cuanto a los resultados de los experimentos se puede afirmar que VGG11Small, agregar Batch Normalization resultó clave para que la red pudiera aprender: sin ella, el modelo llegó apenas a un 34.38% de accuracy en test durante la Tarea 1, y en el Experimento 2 se quedó bloqueada en un 25.05%, que equivale a clasificar al azar entre las 4 clases. Al incorporar BN con un learning rate de 0.001, el rendimiento subió hasta un 83.31%, una diferencia considerable que refleja cuánto afecta la inestabilidad de los gradientes en redes profundas cuando no se controla de alguna manera.

En LeNet-5 ocurrió lo contrario, lo cual fue uno de los hallazgos más llamativos del proyecto. La versión sin BN superó a la que sí la tenía (74.79% vs. 51.31%), algo que a primera vista puede parecer contradictorio. Una explicación razonable es que LeNet es una red muy pequeña, con solo dos bloques convolucionales, y en ese contexto la normalización parece interferir más de lo que aporta. Esto deja una lección clara: no hay técnicas universalmente buenas, todo depende de la arquitectura.

El Experimento 2 también mostró los límites de BN. Con un learning rate de 0.01, VGG11Small con BN igualmente colapsó y volvió al nivel del azar. La normalización estabiliza el entrenamiento hasta cierto punto, pero no alcanza para compensar actualizaciones de peso demasiado agresivas.

Respecto al Transfer Learning con ResNet-18, la estrategia de Feature Extraction obtuvo un 59.43% de accuracy, un resultado más bien modesto. Esto se explica porque los pesos pre entrenados en ImageNet fueron ajustados para reconocer objetos del mundo cotidiano, y las texturas de células sanguíneas son suficientemente distintas como para que ese conocimiento no se transfiera bien cuando los pesos se mantienen congelados.

El mejor resultado del proyecto lo obtuvo el Fine-tuning Total, con un 85.77% de accuracy en test. Al descongelar todas las capas y entrenar con un learning rate muy bajo (0.00001), el modelo logró adaptar sus filtros al dominio médico sin perder lo que ya había aprendido. El Fine-tuning Parcial también funcionó bien, alcanzando un 81.54%, y en situaciones donde los datos disponibles fueran más escasos sería probablemente la alternativa más prudente, dado que maneja menos parámetros y reduce el riesgo de sobreajuste.

En el análisis por clase, los Linfocitos se clasificaron perfectamente (precisión, recall y F1 de 1.00), lo que tiene sentido considerando que morfológicamente son muy distintos al resto: su núcleo grande y redondeado los hace fácilmente reconocibles. El mayor problema lo presentaron los Neutrófilos, que con frecuencia se confundieron con Eosinófilos. Ambas células pertenecen al mismo linaje granulocítico y comparten características estructurales muy similares, y al trabajar con imágenes reducidas a 64×64 píxeles, los pequeños detalles de color y textura que las diferencian quedan prácticamente borrados.

4.2. Limitaciones del proyecto

Una de las limitaciones más notorias del proyecto fue la reducción de resolución. Las imágenes originales del dataset miden 320×240 píxeles, pero tuvieron que reducirse a 64×64 para que el entrenamiento fuera manejable en tiempo y recursos. El problema es que esa compresión elimina precisamente los detalles más finos, que son los que más importan cuando se trata de distinguir entre células morfológicamente parecidas.

Otra restricción que se hizo evidente fue la dependencia de las redes profundas hacia Batch Normalization. VGG11Small sin BN simplemente no logra converger, lo que muestra que entrenar este tipo de arquitecturas desde cero sin ese mecanismo de estabilización es muy difícil, especialmente en entornos con recursos computacionales limitados.

Finalmente, en las tareas de Transfer Learning el entrenamiento se limitó a 5 épocas, y las curvas de aprendizaje al finalizar todavía iban en ascenso. Eso sugiere que los modelos no llegaron a estabilizarse del todo, y que con más épocas de entrenamiento los resultados probablemente habrían sido mejores.

4.3. Propuestas de mejora

Dado que ya se emplearon rotaciones y volteos leves en la etapa de preprocesamiento, una mejora que podría tener bastante impacto es aplicar técnicas más avanzadas y agresivas de data augmentation. Incorporar variaciones de color (como ColorJitter), recortes aleatorios (RandomCrop) o técnicas de regularización visual (como CutMix o MixUp) llevaría a la red a concentrarse en la morfología real de las células, en lugar de depender de características secundarias como el fondo del microscopio. Esto sería especialmente útil para obligar al modelo a encontrar texturas determinantes que reduzcan la confusión entre Neutrófilos y Eosinófilos.

Otra mejora relevante sería aumentar la resolución de entrada de forma progresiva, pasando de 64×64 a 128×128 o directamente a 224×224 , que es el tamaño con el que ResNet fue originalmente entrenada. Para evitar que esto incremente demasiado el número de parámetros en las capas finales, se podría incorporar una capa de Global Average Pooling antes del clasificador, lo que mantiene la red manejable sin sacrificar la información espacial.

Por último, ampliar el número de épocas a entre 15 y 20, combinado con un scheduler de learning rate como ReduceLROnPlateau, daría al modelo más margen para seguir ajustándose en fases avanzadas del entrenamiento. Esto ayudaría a que las actualizaciones de pesos sean más conservadoras cuando el modelo ya está cerca de converger, reduciendo el riesgo de que oscile sin llegar a estabilizarse.

5. Conclusiones

A partir de los experimentos realizados y el análisis de los resultados obtenidos en la clasificación de células sanguíneas, se derivan las siguientes conclusiones principales:

- El éxito del Transfer Learning depende del nivel de adaptación (Fine-Tuning): Se comprobó que el conocimiento genérico de una red preentrenada (ResNet-18) no se transfiere automáticamente a imágenes microscópicas si los pesos se mantienen congelados (Feature Extraction obtuvo solo 59.43%). Sin embargo, al aplicar Fine-Tuning Total y descongelar la red con una tasa de aprendizaje baja (0.00001), el modelo logró el mejor rendimiento de todo el proyecto (85.77%), demostrando que la adaptación profunda de los filtros es indispensable para dominios médicos especializados.
- La eficacia de Batch Normalization es dependiente de la arquitectura: Se demostró empíricamente que Batch Normalization no es una técnica de mejora universal. Mientras que en redes profundas (VGG11Small) fue el factor determinante para permitir la convergencia y alcanzar un 83.31% entrenando desde cero, en arquitecturas superficiales (LeNet-5) su aplicación resultó contraproducente, interfiriendo con el aprendizaje y reduciendo la exactitud.
- El ajuste del Learning Rate sigue siendo crítico: Aunque la normalización por lotes aporta estabilidad al entrenamiento de redes profundas, no las vuelve inmunes a hiperparámetros mal calibrados. Un learning rate excesivamente agresivo (0.01) provocó la divergencia de la función de pérdida incluso en modelos con BN, confirmando que la regularización no reemplaza la necesidad de una búsqueda cuidadosa de hiperparámetros.
- La resolución de imagen es el principal cuello de botella morfológico: La distinción entre células de linajes diferentes (linfocitos) es fácilmente asimilada por las redes neuronales, logrando un 100% de precisión. Sin embargo, diferenciar células del mismo linaje granulocítico (neutrófilos y eosinófilos) requiere identificar detalles de textura fina que se destruyen al comprimir las imágenes a 64x64 píxeles. El aumento de resolución es una condición técnica necesaria para superar el techo de rendimiento actual del modelo.

6. Referencias

- Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998, doi: 10.1109/5.726791.
- A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems*, vol. 25, 2012, doi: 10.1145/3065386.
- K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv:1409.1556*, 2014. doi: 10.48550/arXiv.1409.1556.
- K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.
- S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” *arXiv:1502.03167*, 2015, doi: 10.48550/arXiv.1502.03167.

7. Anexos

- Link del repositorio en Github:
https://github.com/Axel-Pariona/dl-semana6-Acunia_Chui_Meza_Pariona